



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده علوم کامپیوتر

پروژه کارشناسی
گرایش الگوریتم و نظریه محاسبه

رویکردی نوین بر امنیت اطلاعات: از پیچیدگی تجزیه
اعداد تا یادگیری عمیق ماشین

پروژه درس نرم افزار ریاضی

نگارش
پرهام رحیمی

استاد راهنما
بهزاد نجفی سقزچی

استاد درس
امین حسینقلی زاده

خرداد ۱۴۰۵

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

فهرست مطالب

صفحه

عنوان

۱	مقدمه و مفاهیم اولیه
۲	۱-۱ تاریخچه و اهمیت تجزیه اعداد
۳	۲-۱ تعاریف پایه ریاضی
۴	۳-۱ ساختار مستند
۵	۲ مدل سازی ریاضی و الگوریتم ها
۶	۱-۲ مقدمه و مدل سازی ریاضی
۶	۲-۱-۱ توابع چندضابطه ای و حد
۶	۲-۱-۲ بسط چند جمله ای و انتگرال گیری
۷	۳-۱-۲ امید ریاضی و واریانس
۷	۴-۱-۲ تجزیه یک عبارت
۸	۲-۲ الگوریتم بهینه سازی و روندنما
۸	۱-۲-۲ شبه کد الگوریتم
۱۰	۲-۲-۲ روندنمای فرآیند
۱۱	۳ توابع زیان و ارزیابی مدل ها
۱۲	۱-۳ مقدمه
۱۲	۲-۳ منظم سازی و رگرسیون ريج
۱۳	۳-۳ تابع زیان هیوبر
۱۴	۴-۳ معادله نرمال
۱۴	۵-۳ الگوریتم های بهینه سازی
۱۵	۶-۳ معیارهای ارزیابی مدل ها
۱۵	۱-۶-۳ معیارهای ارزیابی در مسائل رگرسیون
۱۶	۲-۶-۳ معیارهای ارزیابی در مسائل دسته بندی
۱۷	۴ شبکه های عصبی عمیق
۱۸	۱-۴ مقدمه
۱۸	۲-۴ یاخته عصبی مصنوعی
۲۰	۳-۴ شبکه های عصبی چندلایه
۲۰	۱-۳-۴ ساختار لایه ها
۲۰	۲-۳-۴ توابع فعال ساز رایج
۲۲	۳-۳-۴ توابع زیان
۲۲	۴-۴ آموزش شبکه عصبی

۲۲	انتشار رو به جلو و پس انتشار خطا ۱-۴-۴
۲۳	الگوریتم‌های بهینه‌سازی ۲-۴-۴
۲۴	کاربردهای شبکه‌های عصبی عمیق ۵-۴
۲۵	جمع‌بندی و نتیجه‌گیری و پیشنهادات ۵
۲۶	جمع‌بندی و نتیجه‌گیری ۱-۵
۲۷	پیشنهادهای برای کارهای آینده ۲-۵
۲۸	منابع و مراجع

شکل	فهرست تصاویر	صفحه
۱-۱	نمایش هندسی و الگوهای توزیع اعداد اول در مارپیچ اولام	۳
۲-۱	گراف ارتباط فصول و ساختار مستند	۴
۱-۲	فلوچارت فرآیند بهینه‌سازی و بررسی شرط توقف	۱۰
۱-۳	مقایسه رفتار توابع خطای مربعات ، خطای مطلق و زیان هیوبر ($\delta = 1$)	۱۳
۱-۴	ساختار یاخته عصبی طبیعی در سیستم عصبی و مدل‌سازی یاخته عصبی مصنوعی	۱۹

صفحه	فهرست جداول	جدول
۱۲	۱-۳ معرفی توابع زیان و روابط تحلیلی در ارزیابی مدل	
۱۵	۲-۳ مقایسه الگوریتم‌های بهینه‌سازی مختلف	

فهرست نمادها

مفهوم	نماد
تابع فعال ساز سیگموید	σ
تابع فعال ساز تانژانت هیپربولیک	$\tanh$
نرخ یادگیری در الگوریتم های بهینه سازی	α
پارامترهای میانگین متحرک (نمایی) در الگوریتم بهینه ساز آدام	β_1, β_2
مقدار ثابت کوچک برای جلوگیری از خطای تقسیم بر صفر در الگوریتم آدام	ϵ
تابع زیان مانند تابع زیان هیوبر	$\mathcal{L}$
مجموعه اعداد حقیقی	$\mathbb{R}$

فصل اول

مقدمه و مفاهیم اولیه

در این فصل به بررسی مفاهیم پایه‌ای و تاریخچه تجزیه اعداد صحیح می‌پردازیم.


۱-۱ تاریخچه و اهمیت تجزیه اعداد

اعداد اول همواره به عنوان آجرهای سازنده ریاضیات و پایه و اساس نظریه اعداد شناخته می‌شوند. بر اساس اصول بنیادین ریاضی، هر عدد صحیح بزرگتر از یک، یا خود یک عدد اول است و یا می‌توان آن را به صورت ضرب چند عدد اول نوشت. فرایند یافتن این عوامل سازنده، «تجزیه عدد صحیح»^۱ نامیده می‌شود. در حالی که ضرب کردن دو عدد اول بسیار بزرگ به راحتی و در کسری از ثانیه توسط رایانه‌ها انجام می‌شود، فرایند معکوس آن، یعنی یافتن عوامل اول یک عدد بسیار بزرگ، مسئله‌ای به شدت زمان‌بر و از نظر محاسباتی پیچیده است. همین عدم تقارن محاسباتی، پایه و اساس سامانه‌های رمزنگاری کلید عمومی نوین را تشکیل می‌دهد که امروزه امنیت ارتباطات دیجیتال، تراکنش‌های بانکی و تبادل داده‌ها در اینترنت به آن وابسته است.^[۵] با وجود اینکه اعداد اول نقش محوری در امنیت و محاسبات دارند، نحوه توزیع آن‌ها در میان اعداد طبیعی همواره یکی از اسرارآمیزترین مباحث ریاضیات بوده است. اعداد اول در نگاه اول رفتاری کاملاً تصادفی و بی‌نظم از خود نشان می‌دهند، اما ریاضی‌دانان با استفاده از نمایش‌های هندسی، الگوهای پنهان شگفت‌انگیزی را در میان آن‌ها کشف کرده‌اند. یکی از معروف‌ترین این نمایش‌ها «مارپیچ اولام»^۲ است که نشان می‌دهد توزیع اعداد اول کاملاً تصادفی نیست.^[۸]

همان‌طور که در شکل ۱-۱ مشاهده می‌شود، اگر اعداد طبیعی را به صورت مارپیچی حول یک نقطه مرکزی بنویسیم و اعداد اول را علامت‌گذاری کنیم، الگوهای بصری خاصی نمایان می‌شود. در زیرشکل ۱-۱ (آ)، نحوه ساختاردهی اولیه این مارپیچ و جایگاه اعداد اول (خانه‌های قرمز رنگ) را در یک مقیاس کوچک نشان می‌دهد. با گسترش این شبکه مارپیچی در مقیاس‌های بسیار بزرگتر، همان‌طور که در زیرشکل ۱-۱ (ب) قابل مشاهده است، اعداد اول به شکل معناداری روی خطوط قطری خاصی متمرکز می‌شوند. این رفتار هندسی نشان می‌دهد که مسئله تجزیه اعداد و درک رفتار اعداد اول، فراتر از محاسبات پیچیده جبری، دارای ساختارهای عمیق هندسی و بصری نیز هست که الگوریتم‌های مدرن به دنبال کشف و بهره‌برداری از آن‌ها هستند.

¹Integer Factorization

²Ulam Spiral



زیر شکل (آ) ساختار اولیه مارپیچ و جایگاه اعداد اول زیر شکل (ب) ظهور الگوهای قطری و تراکم اعداد اول (خانه‌های قرمز رنگ) در مقیاس کوچک

شکل ۱-۱: نمایش هندسی و الگوهای توزیع اعداد اول در مارپیچ اولام

۲-۱ تعاریف پایه ریاضی

برای درک بهتر الگوریتم‌های تجزیه، ابتدا باید برخی از مفاهیم اولیه نظریه اعداد را مرور کنیم. قضیه اساسی حساب بیان می‌کند که هر عدد صحیح و بزرگ‌تر از یک مانند n را می‌توان به صورت یکتایی (صرف نظر از ترتیب) به صورت حاصل ضرب اعداد اول نوشت. [۳] این موضوع در رابطه (۱-۱) نشان داده شده است:

$$n = p_1^{e_1} \cdot p_2^{e_2} \cdots p_k^{e_k} = \prod_{i=1}^k p_i^{e_i} \quad (1-1)$$


که در آن نمادهای p_i اعداد اول متمایز و e_i توان‌های صحیح و مثبت هستند. همچنین در بررسی الگوریتم‌ها، گاهی نیاز به تعریف توابع ریاضی برای جداسازی حالت‌های مختلف داریم. برای مثال، تابع نشانگر اول بودن یک عدد مانند $I(n)$ را می‌توان به صورت یک تابع چندضابطه‌ای به شکل زیر تعریف کرد:

$$I(n) = \begin{cases} 1 & \text{اگر } n \text{ یک عدد اول باشد} \\ 0 & \text{در غیر این صورت} \end{cases} \quad (2-1)$$

روابط (۱-۱) و (۲-۱) پایه و اساس درک الگوریتم‌هایی هستند که در فصل‌های بعدی به آن‌ها خواهیم پرداخت.

۳-۱ ساختار مستند

در رَوَندِنامی^۳ شکل ۲-۱ نمای کلی و سازمان‌دهی مطالب این مستند ارائه می‌شود تا خواننده دید روشنی نسبت به مسیر پیشبرد مباحث داشته باشد:



شکل ۲-۱: گراف ارتباط فصول و ساختار مستند

³Flowchart

فصل دوم

مدل سازی ریاضی و الگوریتم ها

۱-۲ مقدمه و مدل سازی ریاضی

در این فصل، به بررسی چارچوب ریاضی و مدل سازی های انجام شده در این مستند پرداخته می شود. هدف اصلی، ارائه یک ساختار تحلیلی منسجم برای توصیف رفتار سیستم و ارزیابی عملکرد آن است.

۱-۱-۲ توابع چندضابطه ای و حد

توابع چندضابطه ای در مدل سازی پدیده هایی که رفتار آن ها در بازه های مختلف تغییر می کند، کاربرد فراوانی دارند. فرض کنید x یک متغیر حالت باشد؛ در این صورت، تابع $f(x)$ را می توان به صورت رابطه (۱-۲) تعریف کرد:

$$f(x) = \begin{cases} x^2 + 2x & x \geq 0 \\ -x^3 & x < 0 \end{cases} \quad (1-2)$$

همان طور که مشاهده می شود، رفتار تابع در مرز $x = 0$ تغییر می کند. برای بررسی رفتار مجانبی سامانه، محاسبه حد تابع در بی نهایت ضروری است که به صورت رابطه (۲-۲) بیان می شود:

$$\lim_{x \rightarrow \infty} f(x) = \infty. \quad (2-2)$$

۲-۱-۲ بسط چندجمله ای و انتگرال گیری

برای تقریب رفتار غیرخطی سامانه، می توان از بسط چندجمله ای استفاده نمود. فرض کنید N یک عدد صحیح و نشان دهنده مرتبه چندجمله ای باشد. در این حالت، چندجمله ای $P(x)$ به فرم رابطه (۳-۲) ارائه می گردد:

$$P(x) = \sum_{n=0}^N a_n x^n. \quad (3-2)$$

به منظور محاسبه مساحت زیر نمودار یا ارزیابی انرژی سامانه در بازه $[a, b]$ ، از عملگر انتگرال گیری مطابق رابطه (۴-۲) استفاده می شود:

$$\int_a^b P(x) dx = F(b) - F(a). \quad (4-2)$$

۳-۱-۲ امید ریاضی و واریانس

برای تعمیم این مفاهیم و بررسی دقیق تر رفتارهای آماری، فرض کنید X یک متغیر تصادفی پیوسته با تابع چگالی احتمال^۱ $f_X(x)$ باشد و $g(X)$ یک تابع پیوسته و دلخواه روی این متغیر تعریف نماید. بر اساس قضیه آماردان ناآگاه^۲، امید ریاضی برای تابع $g(X)$ با استفاده از انتگرال گیری بر روی کل دامنه متغیر تصادفی به شکل زیر محاسبه می گردد:

$$\mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x)f_X(x) dx, \quad (5-2)$$

همچنین با استفاده از گشتاور دوم، واریانس این تابع تعمیم یافته به صورت رابطه زیر به دست می آید:

$$\text{Var}(g(X)) = \int_{-\infty}^{+\infty} (g(x) - \mathbb{E}[g(X)])^2 f_X(x) dx. \quad (6-2)$$

همان طور که در روابط (۵-۲) و (۶-۲) مشاهده می شود، استفاده از ساختار انتگرالی به ما اجازه می دهد تا رفتار مدل را در فضاهای پیوسته با دقت بالاتری ارزیابی کنیم.

۴-۱-۲ تجزیه یک عبارت

در بسیاری از مسائل تحلیلی و محاسبات عددی، کار با یک فرم بسته و پیچیده ریاضی دشوار است. در این موارد، از تکنیک تجزیه کسر جزئی^۳ برای شکستن یک عبارت گویای پیچیده به مجموعه ای از کسرهای ساده تر استفاده می شود. فرض کنید عبارت گویای $R(x)$ به صورت زیر تعریف شده باشد:

$$R(x) = \frac{x^2 + 4x + 1}{x^3 - x} \quad (7-2)$$

برای تجزیه این عبارت، ابتدا مخرج کسر را به عوامل اول تجزیه کرده و سپس کسر اولیه را به عنوان مجموعی از کسرهای ناشناخته با ضرایب مجهول بازنویسی می کنیم. این فرآیند بسط و تجزیه در چند

¹Probability Density Function (PDF)

²Law of the Unconscious Statistician (LOTUS)

³Partial Fraction Decomposition

خط به صورت زیر قابل نمایش است:

$$\begin{aligned}\frac{x^2 + 4x + 1}{x^3 - x} &= \frac{x^2 + 4x + 1}{x(x-1)(x+1)} \\ &= \frac{A}{x} + \frac{B}{x-1} + \frac{C}{x+1} \\ &= \frac{A(x^2-1) + B(x^2+x) + C(x^2-x)}{x(x-1)(x+1)}\end{aligned}\quad (8-2)$$

همان طور که در رابطه (8-2) مشاهده می شود، با هم مخرج کردن سمت راست تساوی و برابر قرار دادن صورت کسرها، یک دستگاه معادلات خطی⁴ برای یافتن ضرایب A ، B و C شکل می گیرد:

$$\begin{aligned}x^2 : \quad A + B + C &= 1, \\ x^1 : \quad B - C &= 4, \\ x^0 : \quad -A &= 1.\end{aligned}$$

حل دستگاه معادلات بالا به سادگی مقادیر مجهول را به دست می دهد و در نهایت عبارت پیچیده اولیه به فرمی ساده تر و قابل انتگرال گیری یا مشتق گیری تجزیه می گردد.

۲-۲ الگوریتم بهینه سازی و روندنما

برای یافتن مقادیر بهینه پارامترهای مدل، از الگوریتم های بهینه سازی⁵ مبتنی بر تکرار استفاده شده است. یکی از روش های کارآمد در این زمینه، روش گرادیان کاهشی⁶ است. [6] در این بخش، شبه کد⁷ و روندنمای مربوط به این الگوریتم با در نظر گرفتن معیار توقف بر اساس خطای⁸ محاسباتی، ارائه می گردد.

۱-۲-۲ شبه کد الگوریتم

روند اجرایی روش گرادیان کاهشی در قالب الگوریتم ۱ تدوین شده است. در این ساختار، نماد e_{rr} نشان دهنده میزان خطای فعلی، ϵ آستانه تحمل خطا و $N_{\max}$ حداکثر تعداد تکرار مجاز است. در الگوریتم ۱، شبه کد مربوط به روش بهینه سازی گرادیان کاهشی⁹ ارائه شده است. این روش، یک

⁴System of Linear Equations

⁵Optimization Algorithms

⁶Gradient Descent

⁷Pseudocode

⁸Error

⁹Gradient Descent

الگوریتم تکرارشونده برای یافتن نقطه کمینه محلی یک تابع هدف مشتق پذیر است. همان طور که در روند اجرای این الگوریتم مشاهده می شود، کار با دریافت حدس اولیه برای پارامترها (θ_0) ، نرخ یادگیری^{۱۰} (α) که طول گام‌ها را کنترل می کند، حد تحمل خطا (ϵ) و حداکثر تعداد تکرار مجاز $(N_{\max})$ آغاز می گردد. در ابتدا، مقدار خطای اولیه بی نهایت و شمارنده تکرارها صفر در نظر گرفته می شود.

در هر تکرار از حلقه، مراحل زیر اجرا می گردد:

ابتدا بردار گرادیان تابع هزینه J نسبت به پارامترها، یعنی $\nabla J(\theta_k)$ ، در نقطه فعلی محاسبه می شود. این بردار جهت بیشترین افزایش تابع را نشان می دهد. سپس، الگوریتم با استفاده از رابطه به روزرسانی $\theta_{k+1} = \theta_k - \alpha \nabla J(\theta_k)$ گامی به اندازه α در خلاف جهت گرادیان برمی دارد تا مقدار تابع هزینه کاهش یابد. پس از به روزرسانی پارامترها، مقدار خطای جدید (e_{rr}) به صورت نرم اقلیدسی اختلاف مقادیر جدید و قدیم پارامترها محاسبه می شود.

این فرآیند تا زمانی تکرار می شود که شرط توقف ارضا گردد؛ یعنی یا مقدار خطای e_{rr} از حد ϵ تعیین شده کمتر شود (که نشان دهنده همگرایی الگوریتم است)، و یا تعداد تکرارها (k) به سقف مجاز $N_{\max}$ برسد تا از افتادن در حلقه های بی نهایت جلوگیری شود. در نهایت، بهترین مقادیر یافت شده برای پارامترها به عنوان خروجی بازگردانده می شوند.

الگوریتم ۱ الگوریتم گرادیان کاهشی

ورودی: پارامترهای اولیه θ_0 ، نرخ یادگیری α ، حد تحمل ϵ ، حداکثر تکرار $N_{\max}$
خروجی: پارامترهای بهینه شده θ^*

۱: $e_{rr} \leftarrow \infty$

۲: $k \leftarrow 0$

۳: **تا زمانی که** $e_{rr} > \epsilon \wedge k < N_{\max}$ **انجام بده**

۴: $\nabla J(\theta_k) \leftarrow \frac{\partial J}{\partial \theta} \Big|_{\theta=\theta_k}$

۵: $\theta_{k+1} \leftarrow \theta_k - \alpha \nabla J(\theta_k)$

۶: $e_{rr} \leftarrow ||\theta_{k+1} - \theta_k||_2$

۷: $k \leftarrow k + 1$


۸: **پایان تا زمانی که**

۹: **بازگردان** θ_k

¹⁰Learning Rate

۲-۲-۲ روندنمای فرآیند

به منظور درک بهتر روند اجرای الگوریتم ۱، روندنما مربوطه در شکل ۱-۲ رسم شده است. این شکل به وضوح نشان می دهد که چگونه متغیرهای حالت و مقدار خطا در هر تکرار به روزرسانی می شوند تا زمانی که شرط توقف برآورده گردد.



شکل ۱-۲: فلوچارت فرآیند بهینه سازی و بررسی شرط توقف

فصل سوم

توابع زیان و ارزیابی مدل‌ها

۱-۳ مقدمه

در این فصل به بررسی انواع توابع زیان^۱، روش‌های منظم‌سازی^۲ و ارزیابی مدل‌های یادگیری ماشین می‌پردازیم. انتخاب تابع زیان مناسب، تأثیر مستقیمی بر نحوه همگرایی الگوریتم و مقاومت آن در برابر نویز و داده‌های پرت^۳ دارد. جدول ۱-۳ خلاصه‌ای از سه رابطه کلیدی را که در بخش‌های آتی این فصل مورد بحث و بررسی دقیق‌تر قرار می‌گیرند، نشان می‌دهد.

جدول ۱-۳: معرفی توابع زیان و روابط تحلیلی در ارزیابی مدل

نام رابطه	فرمول ریاضی
تابع هزینه رگرسیون ریج	$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2 \quad (1-3)$
تابع زیان هیوبر	$L_{\delta}(e) = \begin{cases} \frac{1}{2}e^2 & \text{اگر } e \leq \delta \\ \delta e - \frac{1}{2}\delta^2 & \text{در غیر این صورت} \end{cases} \quad (2-3)$
معادله نرمال	$\theta = (X^T X + \lambda I)^{-1} X^T y \quad (3-3)$

۲-۳ منظم‌سازی و رگرسیون ریج

هنگامی که مدل ما دچار بیش‌برازش^۴ می‌شود، یکی از راهکارهای مرسوم استفاده از تکنیک‌های منظم‌سازی است. همان‌طور که در رابطه (۱-۳) از جدول ۱-۳ مشاهده کردید، تابع هزینه رگرسیون ریج^۵ از دو بخش تشکیل شده است. بخش اول همان خطای میانگین مربعات است و بخش دوم یک عبارت جریمه^۶ بر مبنای نرم L_2 بردار وزن‌هاست.

¹Loss Functions

²Regularization

³Outliers

⁴Overfitting

⁵Ridge Regression


⁶Penalty Term

این جریمه که با ضریب λ کنترل می‌شود، از رشد بی‌رویه مقادیر پارامترهای θ_j جلوگیری می‌کند و در نتیجه پیچیدگی مدل را کاهش می‌دهد.

۳-۳ تابع زیان هیوبر

در بسیاری از مسائل رگرسیون، استفاده از خطای میانگین مربعات^۷ به عنوان تابع هزینه، مدل را به شدت نسبت به داده‌های پرت^۸ حساس می‌کند؛ زیرا خطاهای بزرگ به توان دو می‌رسند و جریمه سنگینی به مدل تحمیل می‌کنند.

برای مقابله با این مشکل، از تابع زیان هیوبر^۹ استفاده می‌شود.^[۲] همان‌طور که در رابطه (۲-۳) از جدول ۱-۳ مشخص است، این تابع به صورت چندضابطه‌ای تعریف می‌شود. تابع هیوبر ترکیبی از بهترین ویژگی‌های خطای میانگین مربعات^{۱۰} و خطای میانگین مطلق است. یک پارامتر تنظیم‌کننده به نام δ در این تابع وجود دارد که اگر اندازه خطا (یعنی e) کمتر یا مساوی δ باشد، تابع رفتار مربعی از خود نشان می‌دهد که باعث مشتق‌پذیری و همگرایی نرم‌تر در نزدیکی نقطه بهینه می‌شود. اما اگر خطا از δ بیشتر شود (که معمولاً نشان‌دهنده یک داده پرت است)، تابع رفتار خطی پیدا می‌کند و از رشد بی‌رویه گرادیان‌ها جلوگیری می‌نماید. همان‌طور که در شکل ۱-۳ مشاهده می‌شود، رفتار توابع زیان مختلف در برابر خطای پیش‌بینی کاملاً متفاوت است.



شکل ۱-۳: مقایسه رفتار توابع خطای مربعات، خطای مطلق و زیان هیوبر ($\delta = 1$).

⁷Mean Squared Error (MSE)

⁸Outliers

⁹Huber Loss

¹⁰Mean Absolute Error (MAE)

در این نمودار، محور افقی نشان‌دهنده میزان خطا (تفاضل مقدار پیش‌بینی‌شده و مقدار واقعی) و محور عمودی نشان‌دهنده مقدار زیان است. با بررسی نمودار می‌توان به نتایج زیر دست یافت:

- **خطای مربعات (منحنی آبی):** این تابع رشد سهموی دارد. برای خطاهای بزرگتر از ۱ یا کوچکتر از -۱، مقدار زیان به شدت افزایش می‌یابد که نشان‌دهنده حساسیت بالای میانگین مربعات خطا به داده‌های پرت است.
- **خطای مطلق (منحنی قرمز):** این تابع به صورت خطی رشد می‌کند. شیب ثابت این تابع باعث می‌شود در برابر داده‌های پرت مقاوم‌تر باشد، اما مشتق ناپذیری آن در نقطه صفر می‌تواند در فرآیند بهینه‌سازی چالش‌برانگیز شود.
- **زیان هیوبر (منحنی زرد):** در بازه $[-1, 1]$ رفتار منحنی مشابه تابع مربعات است که بهینه‌سازی را هموار می‌کند، اما در خطاهای بزرگتر، رفتار آن مشابه خطای مطلق می‌شود تا در برابر داده‌های پرت مقاومت کند.

۴-۳ معادله نرمال

علاوه بر روش‌های تکرارشونده مانند الگوریتم گرادین کاهشی، برای یافتن پارامترهای بهینه (θ) در مسائل رگرسیون خطی می‌توان از یک راهکار تحلیلی و مستقیم به نام معادله نرمال^{۱۱} استفاده کرد. با صفر قرار دادن مشتق تابع هزینه رگرسیون ریج نسبت به بردار θ ، به رابطه (۳-۳) که در جدول ۱-۳ آورده شده است، دست می‌یابیم. در این رابطه X ماتریس ویژگی‌ها، y بردار مقادیر هدف و I ماتریس همانی است. اضافه شدن عبارت λI (مربوط به جریمه ریج) علاوه بر جلوگیری از بیش‌برازش، یک مزیت مهم دیگر نیز دارد: این عبارت تضمین می‌کند که ماتریس $(X^T X + \lambda I)$ همواره معکوس‌پذیر باشد، حتی اگر تعداد ویژگی‌ها از تعداد نمونه‌های آموزشی بیشتر باشد. با این حال، محاسبه معکوس ماتریس از نظر محاسباتی برای داده‌های بسیار بزرگ هزینه‌بر است و در چنین مواقعی استفاده از گرادین کاهشی ترجیح داده می‌شود.

۵-۳ الگوریتم‌های بهینه‌سازی

در کنار انتخاب توابع زیان مناسب، نحوه کمینه‌سازی این توابع نیز از اهمیت بالایی برخوردار است. الگوریتم‌های بهینه‌سازی وظیفه دارند تا با به‌روزرسانی مکرر پارامترهای مدل، مقدار تابع زیان را به حداقل برسانند. انتخاب الگوریتم مناسب می‌تواند تأثیر چشمگیری بر سرعت همگرایی و کیفیت نهایی مدل داشته باشد.

^{۱۱}Normal Equation

در جدول ۲-۳، مقایسه‌ای بین چند الگوریتم پرکاربرد در یادگیری عمیق و ماشین ارائه شده است. همان‌طور که مشاهده می‌شود، الگوریتم‌های پیشرفته‌تری مانند آدام با وجود نیاز به حافظه کمی بیشتر، سرعت همگرایی بالاتری داشته و در برابر نویز داده‌ها مقاوم‌تر هستند. [۴]

جدول ۲-۳: مقایسه الگوریتم‌های بهینه‌سازی مختلف

نام الگوریتم	سرعت همگرایی	نیاز به حافظه	حساسیت به نویز
گرادیان کاهشی استاندارد	کند	کم	زیاد
گرادیان کاهشی تصادفی	متوسط	کم	بسیار زیاد
الگوریتم آدام	بسیار سریع	متوسط	کم

۳-۶ معیارهای ارزیابی مدل‌ها

پس از آموزش مدل با استفاده از توابع زیان و الگوریتم‌های بهینه‌سازی مناسب، گام بعدی ارزیابی عملکرد مدل بر روی داده‌های آزمون است. معیارهای ارزیابی به ما کمک می‌کنند تا میزان تعمیم‌پذیری مدل را سنجیده و در صورت نیاز، فرایند تنظیم ابرپارامترها را انجام دهیم. بسته به نوع مسئله (رگرسیون یا دسته‌بندی)، از معیارهای متفاوتی استفاده می‌شود.

۳-۶-۱ معیارهای ارزیابی در مسائل رگرسیون

در مسائل رگرسیون، هدف پیش‌بینی یک مقدار پیوسته است. بنابراین، معیارهای ارزیابی معمولاً بر اساس فاصله بین مقادیر واقعی و مقادیر پیش‌بینی شده بنا می‌شوند. دو معیار بسیار پرکاربرد در این زمینه عبارتند از:

میانگین مربعات خطا: این معیار میانگین مربعات اختلاف بین مقادیر واقعی و پیش‌بینی شده را محاسبه می‌کند. به دلیل توان دوم، این معیار خطاهای بزرگتر را با شدت بیشتری جریمه می‌کند.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3-4)$$

میانگین قدر مطلق خطا: این معیار میانگین اندازه خطای مطلق را نشان می‌دهد و بر خلاف معیار قبلی، حساسیت کمتری نسبت به داده‌های پرت دارد.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3-5)$$

۳-۶-۲ معیارهای ارزیابی در مسائل دسته‌بندی

در مسائل دسته‌بندی، خروجی مدل یک کلاس گسسته یا احتمالی از تعلق به یک کلاس است. در اینجا معیارهای ارزیابی بر اساس تعداد پیش‌بینی‌های درست و نادرست تعریف می‌شوند.

دقت: ساده‌ترین معیار ارزیابی است که نسبت تعداد پیش‌بینی‌های صحیح به کل داده‌ها را نشان می‌دهد. اگرچه این معیار شهود خوبی ارائه می‌دهد، اما در صورت نامتوازن بودن کلاس‌ها معیار مناسبی نیست.

آنترپی متقاطع: این معیار که اغلب به عنوان تابع زیان نیز استفاده می‌شود، برای ارزیابی خروجی‌های احتمالی مدل‌های دسته‌بندی (مانند رگرسیون لجستیک یا شبکه‌های عصبی) کاربرد فراوانی دارد. رابطه آن برای یک مسئله چندکلاسه به صورت زیر است:

$$CE = - \sum_{i=1}^C y_i \log(\hat{y}_i) \quad (۳-۶)$$

که در آن C تعداد کلاس‌ها، y_i برچسب واقعی و $\hat{y}_i$ احتمال پیش‌بینی شده برای کلاس i است. همانطور که در روابط (۳-۴) تا (۳-۶) مشاهده می‌شود، انتخاب معیار ارزیابی وابستگی مستقیمی به ماهیت داده‌ها و هدف نهایی مسئله دارد.

فصل چهارم

شبکه‌های عصبی عمیق

۴-۱ مقدمه

شبکه‌های عصبی مصنوعی^۱ یکی از مهم‌ترین زیرشاخه‌های یادگیری ماشین هستند که ساختار و عملکرد آن‌ها از شبکه‌های عصبی بیولوژیکی مغز انسان الهام گرفته شده است [۱]. این شبکه‌ها از تعداد زیادی واحدهای پردازشی ساده به نام یاخته عصبی^۲ تشکیل شده‌اند که به صورت شبکه‌ای به هم متصل هستند. قدرت اصلی شبکه‌های عصبی مصنوعی در توانایی آن‌ها برای یادگیری الگوهای پیچیده و غیرخطی از درون داده‌ها نهفته است، که این ویژگی آن‌ها را برای حل مسائل پیچیده‌ای نظیر بینایی ماشین، پردازش زبان طبیعی و تشخیص گفتار به ابزاری بی‌بدیل تبدیل کرده است.

۴-۲ یاخته عصبی مصنوعی

واحد پایه‌ای و سازنده شبکه‌های عصبی مصنوعی، یاخته عصبی مصنوعی^۳ نام دارد. برای درک بهتر نحوه عملکرد یاخته عصبی مصنوعی، می‌توان ساختار آن را با یک یاخته عصبی زیستی مقایسه کرد. همان‌طور که در شکل ۴-۱ مشاهده می‌شود، می‌توان اجزای یک یاخته عصبی طبیعی (شکل ۴-۱ (آ)) را با معادل‌های ریاضی و منطقی آن در یک یاخته عصبی مصنوعی (شکل ۴-۱ (ب)) تطبیق داد. در شبکه عصبی زیستی، دارینه‌ها^۴ وظیفه دریافت سیگنال‌ها از یاخته‌های عصبی دیگر را بر عهده دارند که این بخش در یاخته عصبی مصنوعی معادل موج‌های ورودی است. هسته^۵ یا بدنه سلول، پردازش موج‌ها را انجام می‌دهد که در مدل مصنوعی با تابع جمع‌کننده خطی و تابع فعال‌ساز جایگزین شده است. در نهایت، آسه^۶ که سیگنال خروجی را به سایر سلول‌ها منتقل می‌کند، معادل خروجی نهایی یاخته عصبی مصنوعی است.

¹ Artificial Neural Networks (ANN)


² Neuron

³ Perceptron

⁴ Dendrites

⁵ Nucleus

⁶ Axon



زیر شکل (آ) ساختار یک یاخته عصبی بیولوژیکی شامل دندریت‌ها، هسته و آکسون
 زیر شکل (ب) مدل ریاضی یک یاخته عصبی مصنوعی شامل ورودی‌ها، وزن‌ها، جمع‌کننده خطی و تابع فعال‌ساز

شکل ۴-۱: ساختار یاخته عصبی طبیعی در سیستم عصبی و مدل‌سازی یاخته عصبی مصنوعی

از نظر ریاضی، عملکرد یک یاخته عصبی مصنوعی را می‌توان با استفاده از رابطه (۴-۱) بیان کرد:

$$y = f \left(\sum_{i=1}^n w_i x_i + b \right) = f(W^T X + b) \quad (4-1)$$

در این معادله:

- متغیر $X = [x_1, x_2, \dots, x_n]^T$ نشان‌دهنده بردار ورودی‌ها است.
- متغیر $W = [w_1, w_2, \dots, w_n]^T$ بردار وزن‌های متصل به هر ورودی را نشان می‌دهد که اهمیت هر موج ورودی را تعیین می‌کند.
- پارامتر b (سوگیری^۷) مقداری است که به مجموع خطی اضافه می‌شود تا انعطاف‌پذیری مدل را برای برازش بهتر داده‌ها افزایش دهد.
- تابع f همان تابع فعال‌ساز^۸ است که ویژگی‌های غیرخطی را به خروجی مدل اضافه کرده و خروجی نهایی یعنی y را تولید می‌کند.

^۷Bias

^۸Activation Function

۳-۴ شبکه‌های عصبی چندلایه

با وجود اینکه یک یاخته عصبی مصنوعی به تنهایی می‌تواند مسائل ساده و خطی را حل کند، اما برای یادگیری الگوهای پیچیده در داده‌های واقعی، به شبکه‌ای از این یاخته‌های عصبی نیاز داریم. اتصال چندین یاخته عصبی به یکدیگر در لایه‌های مختلف، ساختاری را به نام شبکه‌های عصبی چندلایه^۹ شکل می‌دهد.

۱-۳-۴ ساختار لایه‌ها

در یک شبکه عصبی معیار، یاخته‌های عصبی در سه نوع لایه مختلف دسته‌بندی می‌شوند که هر کدام وظیفه خاصی بر عهده دارند:

- **لایه ورودی^{۱۰}:** این لایه نقطه آغازین شبکه است و وظیفه دریافت داده‌های خام را بر عهده دارد. تعداد یاخته‌های عصبی این لایه دقیقاً برابر با تعداد ویژگی‌های^{۱۱} داده‌های ورودی ما است و هیچ‌گونه پردازشی روی داده‌ها انجام نمی‌دهد.
- **لایه‌های پنهان^{۱۲}:** این لایه‌ها بین ورودی و خروجی قرار دارند و قلب تپنده شبکه عصبی محسوب می‌شوند. وظیفه اصلی استخراج الگوها و ویژگی‌های پنهان داده‌ها بر عهده این بخش است. اگر یک شبکه عصبی بیش از یک لایه پنهان داشته باشد، به آن شبکه عصبی عمیق^{۱۳} گفته می‌شود و فرآیند آموزش آن را یادگیری عمیق^{۱۴} می‌نامند.
- **لایه خروجی^{۱۵}:** نتایج نهایی پردازش شبکه، از این لایه به دست می‌آید. تعداد یاخته‌های عصبی لایه خروجی به نوع مسئله بستگی دارد؛ مثلاً در یک مسئله پیش‌بینی قیمت (رگرسیون^{۱۶}) تنها یک یاخته عصبی دارد، اما در مسئله تشخیص اعداد ۰ تا ۹ (دسته‌بندی)، شامل ۱۰ یاخته عصبی خواهد بود.

۲-۳-۴ توابع فعال‌ساز رایج

همان‌طور که در رابطه (۱-۴) دیدیم، توابع فعال‌ساز برای ایجاد خاصیت غیرخطی در شبکه استفاده می‌شوند. بدون وجود این توابع، هرچند شبکه ما لایه‌های بسیار زیادی داشته باشد، باز هم خروجی

^۹Multilayer Perceptron (MLP)

^{۱۰}Input Layer

^{۱۱}Features

^{۱۲}Hidden Layers

^{۱۳}Deep Neural Network (DNN)

^{۱۴}Deep Learning

^{۱۵}Output Layer

^{۱۶}Regression

نهایی صرفاً یک ترکیب خطی ساده از ورودی‌ها خواهد بود و شبکه نمی‌تواند مسائل پیچیده دنیای واقعی را حل کند. در ادامه چهار مورد از پرکاربردترین توابع فعال‌ساز با بیانی ساده معرفی می‌شوند:

۱. تابع سیگموئید^{۱۷}

این تابع، هر عدد ورودی را به یک مقدار خروجی در بازه (۰, ۱) فشرده می‌کند. به دلیل همین ویژگی، معمولاً از این تابع برای مسائلی استفاده می‌شود که نیاز به پیش‌بینی احتمال وقوع یک اتفاق داریم. رابطه ریاضی آن به شکل زیر است:

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-4)$$

۲. تابع تانژانت هذلولوی^{۱۸}

عملکرد این تابع بسیار شبیه به تابع سیگموئید است، با این تفاوت که خروجی‌های آن در بازه (-۱, ۱) قرار می‌گیرند. این موضوع باعث می‌شود میانگین داده‌ها حول عدد ۰ متمرکز شود و معمولاً به یادگیری سریع‌تر شبکه کمک می‌کند:

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (3-4)$$

۳. تابع واحد خطی یکسوساز^{۱۹}

این تابع، امروزه محبوب‌ترین و پرکاربردترین تابع فعال‌ساز در شبکه‌های عمیق است. منطق این تابع بسیار ساده است: اگر ورودی مثبت باشد، خود آن عدد را برمی‌گرداند و اگر منفی باشد، خروجی را برابر صفر قرار می‌دهد. این سادگی ریاضی باعث افزایش چشمگیر سرعت محاسبات در رایانه^{۲۰} می‌شود:

$$f(x) = \max(0, x) \quad (4-4)$$

۴. تابع بیشینه هموار^{۲۱}

این تابع منحصراً در لایه خروجی برای مسائل دسته‌بندی چندطبقه‌ای^{۲۲} استفاده می‌شود. این تابع خروجی تمام یاخته‌های عصبی لایه آخر را به گونه‌ای تنظیم می‌کند که مجموع آن‌ها دقیقاً برابر با عدد ۱ شود. به این ترتیب، می‌توانیم خروجی هر یاخته عصبی را به عنوان درصد احتمال تعلق داده به آن

¹⁷Sigmoid

¹⁸Hyperbolic Tangent (Tanh)

¹⁹Rectified Linear Unit (ReLU)

²⁰Computer

²¹Softmax

²²Multi-class Classification

طبقه ۲۳ در نظر بگیریم:

$$f(x_i) = \frac{e^{x_i}}{\sum_{j=1}^K e^{x_j}} \quad (5-4)$$

که در رابطه بالا، متغیر K نشان‌دهنده تعداد کل طبقه‌ها است.

۳-۳-۴ توابع زیان

پس از آنکه ساختار شبکه عصبی و توابع فعال‌ساز مشخص شدند، نیازمند معیاری هستیم تا میزان خطای شبکه را در پیش‌بینی‌هایش ارزیابی کنیم. تابع زیان^{۲۴} وظیفه محاسبه این خطا را بر عهده دارد. همان‌طور که در فصل ۳ به تفصیل مورد بررسی قرار گرفت و روابط ریاضی آن‌ها بیان شد، بسته به نوع مسئله از توابع متفاوتی استفاده می‌شود؛ در مسائل رگرسیون معمولاً از تابع خطای میانگین مربعات یعنی رابطه (۳-۴) و در مسائل دسته‌بندی از تابع زیان آنتروپی متقاطع یعنی رابطه (۶-۳) استفاده می‌شود. شبکه عصبی با استفاده از الگوریتم‌های بهینه‌سازی تلاش می‌کند تا مقدار این توابع را کمینه کرده و به بهترین پیش‌بینی دست یابد.

۴-۴ آموزش شبکه عصبی

اکنون که ساختار شبکه عصبی، توابع فعال‌ساز و معیار ارزیابی (تابع زیان) مشخص شدند، این پرسش مطرح می‌شود که شبکه چگونه مقادیر بهینه برای وزن‌ها (W) و سوگیری‌ها (b) را پیدا می‌کند تا خطای پیش‌بینی به حداقل برسد؟ فرآیند یادگیری در شبکه‌های عصبی عمیق طی یک چرخه تکرار شونده شامل دو مرحله اصلی انجام می‌شود: انتشار رو به جلو و پس‌انتشار خطا.

۱-۴-۴ انتشار رو به جلو و پس‌انتشار خطا

در مرحله انتشار رو به جلو^{۲۵}، داده‌های ورودی وارد شبکه شده و لایه به لایه در شبکه جلو می‌روند تا در نهایت یک خروجی (پیش‌بینی) تولید شود. سپس با استفاده از تابع زیان، میزان خطای این پیش‌بینی نسبت به مقدار واقعی محاسبه می‌گردد.

پس از محاسبه خطا، مرحله پس‌انتشار خطا^{۲۶} آغاز می‌شود. این الگوریتم که ستون فقرات یادگیری عمیق محسوب می‌شود [۷]، با استفاده از قاعده زنجیره‌ای در حسابان^{۲۷}، مشتق (گرادیان) تابع زیان را

²³Class

²⁴Loss Function

²⁵Forward Propagation

²⁶Backpropagation

²⁷Chain Rule

نسبت به تک‌تک وزن‌ها و سوگیری‌های موجود در شبکه از لایه آخر به سمت لایه اول محاسبه می‌کند. این گرادیان‌ها نشان می‌دهند که هر وزن چقدر در ایجاد خطای نهایی سهم داشته است و برای کاهش خطا باید در چه جهتی تغییر کند.

۲-۴-۴ الگوریتم‌های بهینه‌سازی

پس از محاسبه گرادیان‌ها در مرحله پس‌انتشار، شبکه برای به‌روزرسانی پارامترهای خود از الگوریتم‌های بهینه‌سازی^{۲۸} استفاده می‌کند. پایه و اساس اکثر این الگوریتم‌ها، روش گرادیان کاهشی^{۲۹} است. در این روش، پارامترهای شبکه در خلاف جهت شیب (گرادیان) تابع زیان حرکت می‌کنند تا به کمینه سراسری (کمترین میزان خطا) برسند.

قانون پایه به‌روزرسانی وزن‌ها در الگوریتم گرادیان کاهشی به صورت رابطه (۶-۴) تعریف می‌شود:

$$w_{new} = w_{old} - \alpha \frac{\partial L}{\partial w} \quad (6-4)$$

در این رابطه:

- متغیر w نشان‌دهنده وزن یاخته عصبی است.
 - پارامتر L همان تابع زیان است.
 - عبارت $\frac{\partial L}{\partial w}$ نشان‌دهنده مشتق جزئی (گرادیان) تابع زیان نسبت به وزن است.
 - متغیر α (آلفا) نرخ یادگیری^{۳۰} نام دارد. این پارامتر بسیار مهم، اندازه گام‌های شبکه را در مسیر کاهش خطا تعیین می‌کند. اگر α خیلی بزرگ باشد، ممکن است الگوریتم از نقطه بهینه عبور کند و اگر خیلی کوچک باشد، فرآیند یادگیری بسیار کند خواهد شد.
- امروزه در شبکه‌های عصبی عمیق از نسخه‌های پیشرفته‌تر و تطبیق‌پذیرتر گرادیان کاهشی استفاده می‌شود. یکی از محبوب‌ترین این روش‌ها، بهینه‌ساز آدام^{۳۱} است. [۴] الگوریتم آدام با ترکیب مزایای روش‌های مختلف، نرخ یادگیری را برای هر پارامتر به صورت جداگانه و پویا در طول زمان تنظیم می‌کند که این امر منجر به همگرایی سریع‌تر و دقیق‌تر شبکه در مسائل پیچیده می‌شود.

²⁸Optimization Algorithms

²⁹Gradient Descent

³⁰Learning Rate

³¹Adam Optimizer

۵-۴ کاربردهای شبکه‌های عصبی عمیق

با افزایش توان پردازشی رایانه‌ها و دسترسی به حجم عظیم داده‌ها (کلان داده‌ها)، شبکه‌های عصبی عمیق توانسته‌اند در بسیاری از حوزه‌های علمی و صنعتی تحولات چشمگیری ایجاد کنند. انعطاف‌پذیری این شبکه‌ها در یادگیری الگوهای پیچیده غیرخطی، باعث شده است تا در طیف وسیعی از مسائل به کار گرفته شوند. در ادامه به برخی از مهم‌ترین کاربردهای این شبکه‌ها اشاره می‌شود:

- **امنیت شبکه و فضای سایبری^{۳۲}**: یکی از کاربردهای بسیار مهم و رو به رشد یادگیری عمیق، تامین امنیت شبکه‌های کامپیوتری است. از این شبکه‌ها در سیستم‌های تشخیص نفوذ^{۳۳} برای شناسایی رفتارهای غیرعادی و ترافیک مخرب استفاده می‌شود. شبکه‌های عصبی می‌توانند با تحلیل الگوهای ترافیک شبکه، حملاتی مانند منع سرویس توزیع شده^{۳۴}، بدافزارها و فیشینگ را با دقت و سرعت بسیار بالایی نسبت به روش‌های سنتی شناسایی کنند.^[۹]
- **بینایی ماشین و پردازش تصویر^{۳۵}**: از تشخیص چهره در تلفن‌های هوشمند گرفته تا سیستم‌های بینایی در خودروهای خودران و همچنین تشخیص تومورها در تصاویر پزشکی (مانند تصویربرداری تشدید مغناطیسی^{۳۶} و اشعه ایکس^{۳۷})، همگی از دستاوردهای شبکه‌های عصبی عمیق (به‌ویژه شبکه‌های پیچشی) هستند.
- **پردازش زبان طبیعی^{۳۸}**: درک و تولید زبان انسان توسط ماشین، ترجمه ماشینی (مانند مترجم گوگل)، دستیارهای صوتی هوشمند و چت‌بات‌های پیشرفته، همگی بر پایه معماری‌های عمیق شبکه‌های عصبی بنا شده‌اند.

³²Cyber & Network Security

³³Intrusion Detection Systems (IDS)

³⁴Distributed Denial of Service (DDoS)

³⁵Computer Vision

³⁶MRI

³⁷X-Ray

³⁸Natural Language Processing (NLP)

فصل پنجم

جمع‌بندی و نتیجه‌گیری و پیشنهادات

در این فصل، پس از بررسی جامع مفاهیم پایه‌ای، مدل‌سازی‌های ریاضی، الگوریتم‌های بهینه‌سازی و ساختار شبکه‌های عصبی عمیق، به جمع‌بندی دستاوردها و نتایج حاصل از این مستند می‌پردازیم. همچنین با تکیه بر دانش نظری به‌دست‌آمده در فصول پیشین، پیشنهادهایی کاربردی و مسیرهایی نوین برای توسعه این پژوهش و انجام کارهای آینده ارائه خواهد شد.

۵-۱ جمع‌بندی و نتیجه‌گیری

هدف اصلی این مستند، ایجاد یک پیوند علمی و منطقی میان مفاهیم بنیادین ریاضیات، الگوریتم‌های محاسباتی و فناوری‌های نوین یادگیری ماشین بود. روند این پژوهش نشان داد که چگونه مسائلی که در نگاه اول صرفاً تئوری به نظر می‌رسند، می‌توانند پایه و اساس فناوری‌های پیچیده امروزی باشند. نتایج و دستاوردهای اصلی این پژوهش را می‌توان در محورهای زیر خلاصه نمود:

- **شناخت الگوهای پنهان در ساختارهای ریاضی:** در فصل نخست نشان داده شد که مسائلی نظیر تجزیه اعداد صحیح و توزیع اعداد اول که پایه و اساس سامانه‌های رمزنگاری و امنیت دیجیتال هستند، دارای رفتارهای هندسی معناداری (مانند مارپیچ اولام) می‌باشند. درک این الگوها پیش‌نیاز توسعه الگوریتم‌های هوشمند است.

- **اهمیت مدل‌سازی و بهینه‌سازی ریاضی:** در فصول دوم و سوم، چارچوب‌های تحلیلی و روش‌های بهینه‌سازی مورد ارزیابی قرار گرفتند. بررسی توابع زیان مختلف (مانند زیان هیوبر در برابر خطای میانگین مربعات) و الگوریتم‌هایی نظیر گرادیان کاهشی و آدام ثابت کرد که انتخاب درست معیار ارزیابی و روش بهینه‌سازی، نقشی حیاتی در مقاومت مدل در برابر داده‌های پرت و سرعت همگرایی آن دارد.

- **قدرت شبکه‌های عصبی در حل مسائل پیچیده:** در فصل چهارم با بررسی ساختار یاخته‌های عصبی مصنوعی و شبکه‌های چندلایه، نشان داده شد که این مدل‌ها به کمک توابع فعال‌ساز غیرخطی و الگوریتم پس‌انتشار خطا، توانایی فوق‌العاده‌ای در استخراج الگوهای پنهان داده‌ها دارند.

- **هم‌گرایی امنیت و هوش مصنوعی:** در نهایت، به عنوان یکی از مهم‌ترین نتایج، مشخص شد که معماری‌های عمیق می‌توانند به عنوان ابزاری قدرتمند برای تامین امنیت فضای سایبری به کار گرفته شوند. مدل‌های یادگیری عمیق با تحلیل ترافیک شبکه توانایی بالایی در شناسایی حملات پیچیده نظیر منع سرویس توزیع‌شده و تشخیص نفوذ دارند و می‌توانند جایگزین قدرتمندی برای روش‌های سنتی مبتنی بر امضا باشند.

به طور خلاصه، این مستند یک چارچوب نظری منسجم فراهم کرد که نشان می‌دهد گذار از امنیت سنتی مبتنی بر پیچیدگی‌های محاسباتی (مانند تجزیه اعداد) به سمت امنیت هوشمند مبتنی بر داده (شبکه‌های عصبی عمیق)، یک مسیر علمی ضروری و اجتناب‌ناپذیر است.

۲-۵ پیشنهادها برای کارهای آینده

با توجه به مباحث نظری مطرح شده و پتانسیل بالای شبکه‌های عصبی عمیق، موارد زیر به عنوان پیشنهادهایی برای توسعه و ادامه این پژوهش در کارهای آینده ارائه می‌گردد:

۱. **پیاده‌سازی عملی مدل‌های تشخیص نفوذ:** پیشنهاد می‌شود در پژوهش‌های آتی، مفاهیم تئوری این مستند به صورت عملی پیاده‌سازی شوند. به عنوان مثال، استفاده از یک مجموعه دادگان^۱ استاندارد ترافیک شبکه و آموزش یک شبکه عصبی عمیق برای تشخیص بلادرنگ^۲ حملات سایبری و مقایسه دقت^۳ آن با روش‌های کلاسیک می‌تواند بسیار ارزشمند باشد.

۲. **استفاده از یادگیری عمیق در تحلیل رمزنگاری:**^۴ با توجه به الگوهای بررسی شده در مارپیچ اولام، یکی از ایده‌های جذاب برای آینده، تغذیه این الگوهای بصری و هندسی اعداد اول به شبکه‌های عصبی (به‌ویژه شبکه‌های عصبی پیچشی^۵) است تا مشخص شود آیا هوش مصنوعی قادر به کشف روابط جدیدی برای تسریع فرآیند تجزیه اعداد صحیح می‌باشد یا خیر.

۳. **بررسی معماری‌های پیشرفته‌تر شبکه‌های عصبی:** در این مستند تمرکز اصلی بر شبکه‌های عصبی چندلایه بود. پیشنهاد می‌شود برای داده‌های توالی‌دار مانند ترافیک شبکه که وابستگی زمانی دارند، از معماری‌های پیشرفته‌تری نظیر شبکه‌های عصبی بازگشتی^۶ یا حافظه طولانی کوتاه‌مدت^۷ استفاده شود.

۴. **ترکیب الگوریتم‌های فراابتکاری با یادگیری عمیق:** بررسی ترکیب الگوریتم‌های بهینه‌سازی تکاملی با روش‌هایی مانند آدام برای فرار از کمینه‌های محلی^۸ و بهبود فرآیند آموزش شبکه‌های عصبی، می‌تواند موضوع یک پژوهش مستقل و نوآورانه باشد.

¹Dataset

²Real-time

³Accuracy

⁴Cryptanalysis

⁵CNN

⁶RNN

⁷LSTM

⁸Local Minima

منابع و مراجع

- [1] Goodfellow, I, Bengio, Y, and Courville, A. Deep learning, mit press. available online. 2016.
- [2] Hampel, Frank R. Introduction to huber (1964) robust estimation of a location parameter. In *Breakthroughs in Statistics: Methodology and Distribution*, pages 479–491. Springer, 1992.
- [3] Hardy, Godfrey Harold and Wright, Edward Maitland. *An introduction to the theory of numbers*. Oxford university press, 1979.
- [4] Kingma, Diederik P and Ba, Jimmy. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [5] Rivest, Ronald L, Shamir, Adi, and Adleman, Leonard. A method for obtaining digital signatures and public-key cryptosystems. *Communications of the ACM*, 21(2):120–126, 1978.
- [6] Ruder, Sebastian. An overview of gradient descent optimization algorithms. *arXiv preprint arXiv:1609.04747*, 2016.
- [7] Rumelhart, David E, Hinton, Geoffrey E, and Williams, Ronald J. Learning representations by back-propagating errors. *nature*, 323(6088):533–536, 1986.

- [8] Stein, Myron L, Ulam, Stanislaw M, and Wells, Mark B. A visual display of some properties of the distribution of primes. *The American Mathematical Monthly*, 71(5):516–520, 1964.
- [9] Xin, Yang, Kong, Lingshuang, Liu, Zhi, Chen, Yuling, Li, Yanmiao, Zhu, Hongliang, Gao, Mingcheng, Hou, Haixia, and Wang, Chunhua. Machine learning and deep learning methods for cybersecurity. *Ieee access*, 6:35365–35381, 2018.